

LH NAUTICAL

DATA CHALLENGE LIGHTHOUSE — DA EXPLORAÇÃO DE DADOS À INTELIGÊNCIA APLICADA

EDA

SQL

Python

Previsão de demanda

Recomendação

Power BI

Samantha Fernandes

Uma campanha na próxima semana, dados completamente desorganizados

A LH Nautical é uma varejista náutica fictícia (lojas físicas, armazéns e e-commerce), com dados operacionais de 2020 a 2026: catálogo, pedidos, pagamentos, NF-e, compras, estoque e devoluções.

O Tech Lead Gabriel Santos foi direto: *“Eu valorizo mais a organização e a explicação do que o código rodando sem eu entender nada.”*

● EDA

Volume, distribuição e qualidade, tratar nada ainda

● Tratamento & modelagem

Schema PostgreSQL + carga bruta via SQL/Python

● Análise de vendas & clientes

SQL sobre o banco relacional


● Previsão & recomendação

Baseline estatístico e similaridade em Python

Pipeline de dados

Do CSV bruto ao painel — cada etapa documentada e com decisões justificadas.

Pipeline de dados — LH Nautical



“Posso confiar nesses dados?”

Análise exploratória da tabela orders . Sem tratamento, só observação e agregação.

48.998

linhas · 13 colunas

2020–2026

intervalo de created_at

R\$ 28.704,99

valor médio (total)

**R\$ 32,62 –
127.262,02**

faixa mín. – máx.

● Outliers

452 registros fora da faixa IQR em “total” — 0,92% das linhas.

● Nulos

49,25% de salesperson_id nulo — precisa de investigação antes de qualquer leitura operacional.

● Datas futuras

8,82% das linhas com created_at à frente da data de referência da análise.

Diagnóstico: base utilizável, mas não pronta para decisão sem tratamento prévio.

Da planilha ao banco relacional


Geração de schema

Criação automática do schema PostgreSQL em Python, a partir dos 24 arquivos CSV.
Carga dos dados

Pontos de atenção

- CPF e telefone foram mantidos como texto para preservar zeros à esquerda.
- Chaves e identificadores foram tratados de acordo com o tamanho dos valores.
- A chave da NF-e foi mantida como texto por possuir 44 dígitos.

Schema relacional — recorte simplificado



Carga dos dados

Carga dos CSVs no PostgreSQL mantendo os dados originais, sem tratamento ou alteração.

Decisão de arquitetura

Separar carga bruta de tratamento evita perder rastro do dado original em caso de erro de regra de negócio.

Os clientes mais fiéis compram de tudo

Top 10 clientes fiéis por ticket médio, entre os que compraram de 13+ categorias distintas.

10 / 10

clientes fiéis compraram das 14 categorias do catálogo inteiro

Categoria mais comprada pelo grupo (unidades)



● **Leitura de negócio**

Com um catálogo de só 14 categorias, diversidade ≥ 13 é um corte quase universal entre clientes engajados , o que já é, em si, um sinal de que fidelidade nesta base está mais ligada a recorrência de compra do que a variedade de categoria.

Dia sme venda não é dia ausente, é zero


generate_series + LEFT JOIN + COALESCE(0) — Questão 5

Inclui dias sem venda como zero na média por dia da semana



generate_series + LEFT JOIN + COALESCE(0), canal POS — sql/05_dimensao_calendario.sql

Previsão de demanda: expectativa × realidade




Achado de qualidade de dados

“Bússola de Bordo 702” tem 2 cadastros com o mesmo nome (ids 74 e 240) — nome não é chave única no catálogo. As 3 variantes de ambos foram usadas em conjunto após confirmar histórico de venda real nas duas.

O que os clientes compram junto com o Motor de Popa 1949?

Sistema de recomendação — similaridade de cosseno (Questão 7)



Recomendação baseada no comportamento dos clientes: produtos comprados por clientes com perfil de compra semelhante ao de quem comprou o Motor de Popa 1949.

● O dado não confirmou a hipótese

A “Defensa Náutica” não ficou entre os 5 produtos mais similares ao “Motor de Popa 1949”. Como existem vários SKUs de defensas no catálogo, as compras ficam distribuídas e a similaridade de cada produto acaba sendo menor

Rentabilidade e devoluções

Análise complementar aos indicadores solicitados no desafio

Como interpretar esses indicadores:

Valor reembolsado: representa o valor devolvido em pedidos com reembolso concluído.

Margem estimada: calculada com base no preço de venda e no custo cadastrado do produto.

Margem acumulada: soma da margem estimada nas vendas consideradas.

R\$ 58.380,75

maior valor reembolsado (Bússola de Bordo 8282)

41,3%

margem estimada média geral

R\$ 529.657,42

margem acumulada do cliente líder (id 740)


● Por que não “prejuízo” nem “lucro” sem qualificar

Valor devolvido não é prejuízo líquido, o item pode voltar ao estoque e ser revendido. E a diferença entre preço de venda e custo cadastrado não é lucro contábil.

Não desconta imposto, frete ou custo operacional. Por isso as views usam “valor reembolsado” e “margem estimada”, com a lógica documentada em SQL.

Visão Executiva

Faturamento, pedidos, ticket médio e sazonalidade, filtros de Ano, Canal e Categoria.



Visão de Clientes

Ticket médio, diversidade de categorias e clientes elite (Questão 4).



O que fica deste desafio

● Dado bruto ≠ dado confiável

EDA sem tratamento já revelou nulos, outliers e datas futuras que mudam o diagnóstico de “pronto para decisão”.

● Regra de negócio muda o resultado

A dimensão de calendário mostrou que considerar os dias sem venda altera a conclusão sobre o pior dia: de domingo para quinta-feira.

● Nome não é chave

Encontramos produtos com nomes duplicados, como "asdf" e "Bússola de Bordo 702". Por isso, as análises por produto foram feitas usando o `product_id`.

● Modelo simples, limite claro

A média móvel prevê bem tendência, mas erra mudança brusca de patamar — risco real de ruptura de estoque.

Repositório completo (SQL, Python, README) no GitHub <https://github.com/Sam-Batisti/lh-nautical-lighthouse-indicium> · painel em dashboard/Dashboard.pbix

Obrigada!